

LAPORAN PRAKTIKUM



Machine Learning Statistik Deskriptif dan Probabilitas – Statistik Deskriptif dan Probabilitas

IDENTITAS

Nama Lengkap	:	Trisa Dhiya Nasywa
NIM	:	0110225049
Program Studi	:	Teknik Informatika
Mata Kuliah	:	Machine Learning
Dosen Pengampu	:	Dr. Sirojul Munir S.Si.,M.Kom
Asisten Dosen/Lab	:	Elyas Randi Renaldi
Tanggal Praktikum	:	Senin, 21 September 2026

Daftar Pustaka

LAPORAN PRAKTIKUM.....	1
IDENTITAS.....	1
BAB I PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Tujuan Praktikum	3
BAB II LANDASAN TEORI.....	5
2.1 Google Colab dan Lingkungan Machine Learning.....	5
2.2 Statistik Deskriptif dan Visualisasi Data.....	5
2.3 Korelasi dan Pembagian Dataset	5
BAB III METODOLOGI PRAKTIKUM.....	6
3.1 Dataset dan Lingkungan Pengembangan	6
3.2 Tahapan Praktikum	6
3.3 Praktikum Mandiri.....	6
BAB IV HASIL DAN PEMBAHASAN.....	7
4.1 Hasil Eksplorasi dan Statistik Data	7
4.2 Hasil Visualisasi dan Korelasi.....	8
4.3 Hasil Data Cleaning dan Encoding.....	11
4.4 Hasil Pembagian Dataset.....	12
BAB V KESIMPULAN DAN SARAN	14
5.1 Kesimpulan	14
5.2 Saran	14
DAFTAR PUSTAKA	15

BAB I PENDAHULUAN

1.1 Latar Belakang

Sebelum membangun model *machine learning* yang kompleks, tahapan awal yang sangat penting dilakukan adalah memahami karakteristik dari dataset yang digunakan. Oleh karena itu, eksplorasi awal dilakukan melalui statistik deskriptif untuk melihat bentuk sebaran data, letak pemusatan data, hingga mengidentifikasi potensi pencilan (*outlier*). Statistik sendiri merupakan cabang ilmu yang mempelajari prosedur pengumpulan, pengolahan, penyajian, hingga penarikan kesimpulan dari data observasi. Sementara itu, probabilitas digunakan untuk mengukur tingkat peluang atau kepastian terjadinya suatu peristiwa berdasarkan model matematis.

Dalam ruang lingkup *machine learning*, konsep probabilitas bersyarat dan Teorema Bayes memainkan peranan penting untuk memutakhirkan estimasi berdasarkan informasi awal (*prior knowledge*). Selain itu, pemahaman terhadap klasifikasi jenis data (kualitatif dan kuantitatif) menjadi acuan dalam menentukan teknik analisis serta *preprocessing* yang tepat. Agar model yang dirancang memiliki kemampuan generalisasi yang baik pada data baru (*unseen data*), dataset perlu dibagi secara terstruktur menjadi bagian *training*, *validation*, dan *testing*. Praktikum ini bertujuan untuk memberikan pengalaman praktis dalam menghitung indikator statistik deskriptif, menyajikan visualisasi data, serta melakukan pembagian dataset secara sistematis.

1.2 Tujuan Praktikum

Tujuan Umum: Memahami dan mengaplikasikan konsep dasar statistik, teori probabilitas, serta pengelolaan dataset untuk analisis data dan pemodelan statistik/pembelajaran mesin (*machine learning*).

Tujuan Khusus:

1. **Latar Belakang Praktikum:** Memahami pentingnya penggunaan metode statistik dan teori probabilitas dalam mengolah, menganalisis, serta menarik kesimpulan yang valid dari suatu data.
2. **Definisi Statistik dan Probabilitas:** Mengidentifikasi serta membedakan konsep statistik (ilmu pengumpulan, analisis, dan interpretasi data) dan probabilitas (ukuran kepastian atau peluang terjadinya suatu peristiwa).
3. **Ruang Probabilitas (*Probability Space*):** Memahami komponen pembentuk ruang probabilitas, yaitu ruang sampel, ruang kejadian/event, dan ukuran probabilitas.
4. **Probabilitas Bayes (*Bayes' Theorem*):** Menghitung probabilitas bersyarat suatu kejadian berdasarkan pengetahuan awal (*prior knowledge*) yang relevan dengan kondisi tersebut.

5. **Data Penelitian Kuantitatif dan Kualitatif:** Mengklasifikasikan jenis-jenis data penelitian berdasarkan bentuknya (data kualitatif/deskriptif dan kuantitatif/numerik) serta tingkat pengukurannya.
6. **Pembagian Dataset (*Training, Testing, Validation*):** Mengaplikasikan teknik pemisahan dataset ke dalam bagian *training* (melatih model), *validation* (mengoptimalkan hiperparameter), dan *testing* (mengevaluasi performa akhir model).
7. **Fungsi-fungsi Statistik Deskriptif:** Menerapkan fungsi-fungsi dasar statistik deskriptif (seperti *mean, median, modus, varians, dan deviasi standar*) untuk meringkas dan menggambarkan karakteristik umum suatu dataset.

BAB II LANDASAN TEORI

2.1 Google Colab dan Lingkungan Machine Learning

Google Colaboratory (Google Colab) merupakan lingkungan pengembangan Python berbasis *cloud* yang berjalan di atas Jupyter Notebook. Google Colab mempermudah proses analisis data karena pustaka-pustaka utama seperti Pandas, NumPy, Matplotlib, Seaborn, dan Scikit-Learn telah terpasang secara bawaan sehingga dapat langsung digunakan tanpa konfigurasi sistem lokal.

2.2 Statistik Deskriptif dan Visualisasi Data

Statistik deskriptif digunakan untuk merangkum dan memberikan gambaran mengenai karakteristik data numerik yang diolah.

- a. **Ukuran Pemusatan Data:** Meliputi *mean* (rata-rata hitung), *median* (nilai tengah setelah data diurutkan), dan *modus* (nilai dengan frekuensi kemunculan terbanyak).
- b. **Ukuran Penyebaran Data:** Meliputi *variansi* (rata-rata kuadrat selisih data terhadap mean), *standar deviasi* (akar dari variansi), dan *Interquartile Range* atau IQR ($Q3 - Q1$) yang menggambarkan sebaran 50% data pada bagian tengah.
- c. **Visualisasi Data:** *Boxplot* digunakan untuk menampilkan ringkasan lima angka penting (Min, Q1, Q2, Q3, Max) serta mengidentifikasi keberadaan *outlier*. *Histogram* menggambarkan distribusi frekuensi dari variabel numerik, sedangkan *Scatter Plot* digunakan untuk mengamati pola hubungan antara dua variabel.

2.3 Korelasi dan Pembagian Dataset

Korelasi Pearson digunakan untuk mengukur tingkat keeratan hubungan linear antara dua variabel numerik, dengan nilai rentang antara -1 hingga +1. Nilai korelasi yang mendekati +1 menunjukkan hubungan positif (searah), nilai yang mendekati -1 menunjukkan hubungan negatif (berlawanan arah), dan nilai mendekati 0 mengindikasikan tidak adanya hubungan linear.

Dalam alur pengembangan *machine learning*, dataset dibagi menjadi tiga bagian utama:

1. **Data Training:** Bagian terbesar dari dataset yang digunakan oleh algoritma untuk mempelajari pola data.
2. **Data Validation:** Digunakan selama proses pelatihan untuk mengevaluasi kinerja model serta mengoptimalkan hiperparameter guna mencegah *overfitting*.
3. **Data Testing:** Data yang diisolasi secara terpisah dari awal (*unseen data*) yang digunakan untuk menguji performa akhir model secara objektif.

BAB III METODOLOGI PRAKTIKUM

3.1 Dataset dan Lingkungan Pengembangan

Praktikum ini menggunakan dua dataset, yaitu 500_Person_Gender_Height_Weight_Index.csv untuk pengolahan statistik deskriptif dan day.csv untuk pemisahan dataset. Peralatan yang digunakan meliputi Google Colab, Google Drive, bahasa pemrograman Python, serta pustaka pendukung seperti Pandas (manipulasi data frame), NumPy (operasional numerik), Matplotlib dan Seaborn (visualisasi data), serta Scikit-Learn (pemisahan dataset).

3.2 Tahapan Praktikum

Tahapan pelaksanaan praktikum meliputi langkah-langkah berikut:

1. Menghubungkan Google Colab dengan direktori penyimpanan Google Drive.
2. Memuat (*loading*) dataset serta memeriksa struktur kolom dan tipe data.
3. Menghitung indikator statistik deskriptif dasar.
4. Membuat visualisasi data (*Boxplot, Histogram, Scatter Plot*) dan menghitung koefisien korelasi.
5. Melakukan tahapan *data cleaning* dan *encoding* pada fitur kategorikal.
6. Membagi dataset menjadi bagian *training*, *validation*, dan *testing*

3.3 Praktikum Mandiri

Pada bagian praktikum mandiri, dilakukan pembagian dataset day.csv dengan skenario 80% untuk *data training*, 10% untuk *data validation* (diambil dari porsi *data training*), dan 20% sisanya langsung dipisahkan sebagai *data testing*. Selanjutnya ditampilkan jumlah record beserta sampel baris teratas dari masing-masing bagian.

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Eksplorasi dan Statistik Data

Pengujian diawali dengan menghitung nilai rata-rata (*mean*) dari variabel tinggi badan (*Height*), yang menghasilkan nilai sebesar 169,944 cm.

```
[9]
✓ Os      #Menghitung mean semua kolom numerik
          df['Height'].mean()

np.float64(169.944)
```

Gambar 4.1 Perhitungan Nilai Rata-rata (Mean) Kolom Height pada Dataset

Selanjutnya, diperoleh nilai tengah (*median*) dari tinggi badan sebesar 170,5 cm.

```
[10]
✓ Os      df['Height'].median()

170.5
```

Gambar 4.2 Perhitungan Nilai Tengah (Median) Kolom Height pada Dataset

Nilai yang paling sering muncul (*modus*) pada variabel tinggi badan adalah sebesar 188 cm.

```
[11]
✓ Os      df['Height'].mode()

Height
0      188
dtype: int64
```

Gambar 4.3 Perhitungan Nilai Modus (Mode) Kolom Height pada Dataset

Untuk mengamati tingkat variabilitas data terhadap rata-ratanya, dilakukan perhitungan varians pada kolom numerik. Hasilnya menunjukkan bahwa variabel Height memiliki nilai varians 268,15, Weight sebesar 1048,63, dan Index sebesar 1,84.

```
[12]
✓ Os      #Menghitung varians
          df.var(numeric_only=True)

0
Height    268.149162
Weight    1048.633267
Index      1.836168
dtype: float64
```

Gambar 4.4 Perhitungan Varians untuk Kolom Numerik pada Dataset

Berdasarkan perhitungan kuartil, didapatkan nilai $Q1 = 156,0$ cm dan $Q3 = 184,0$ cm, sehingga menghasilkan nilai IQR sebesar 28,0 cm.

```
[13]
✓ Os ▶ #Hitung kuartil pertama
q1 = df['Height'].quantile(0.25)
print('Q1:', q1)

#Hitung kuartil ketiga
q3 = df['Height'].quantile(0.75)
print('Q3:', q3)

#Hitung kuartil
iqr = q3 - q1
print('IQR:', iqr)
```

... Q1: 156.0
Q3: 184.0
IQR: 28.0

Gambar 4.5 Perhitungan Nilai Kuartil (Q1, Q3) dan Interquartile Range (IQR)

Seluruh indikator statistik deskriptif ini juga dievaluasi secara serentak menggunakan fungsi `df.describe()`, di mana hasilnya terbukti konsisten dengan kalkulasi sebelumnya.


```
[14]
✓ Os ▶ #Untuk membuat statistika deskripsi pada type data iqr
df.describe()
```

	Height	Weight	Index
count	500.000000	500.000000	500.000000
mean	169.944000	106.000000	3.748000
std	16.375261	32.382607	1.355053
min	140.000000	50.000000	0.000000
25%	156.000000	80.000000	3.000000
50%	170.500000	106.000000	4.000000
75%	184.000000	136.000000	5.000000
max	199.000000	160.000000	5.000000

Gambar 4.6 Ringkasan Statistik Deskriptif Menggunakan Fungsi `describe()`

4.2 Hasil Visualisasi dan Korelasi

Visualisasi sebaran data menggunakan *Boxplot* pada kolom Height menunjukkan distribusi yang relatif simetris tanpa terdeteksi adanya nilai pencilan (*outlier*) di luar batas *whisker*.




Gambar 4.7 Visualisasi Boxplot Variabel Height untuk Deteksi Sebaran Data

Distribusi frekuensi variabel tinggi badan disajikan menggunakan *Histogram* dengan 5 interval kelas. Frekuensi tertinggi berada pada rentang 175–187 cm, sementara rentang lainnya memiliki sebaran yang cukup merata.




Gambar 4.8 Visualisasi Histogram Distribusi Frekuensi Variabel Height

Untuk mengamati pola korelasi secara visual, dilakukan uji coba melalui grafik *Scatter Plot*. Grafik pertama menunjukkan korelasi positif, di mana kenaikan nilai variabel X diikuti oleh kenaikan nilai variabel Y secara searah.




Gambar 4.9 Scatter Plot Contoh Korelasi Positif antara Dua Variabel

Grafik kedua menggambarkan korelasi negatif, di mana peningkatan nilai variabel X berbanding terbalik dengan penurunan nilai variabel Y.



Gambar 4.10 Scatter Plot Contoh Korelasi Negatif antara Dua Variabel

Pada dataset utama, pola hubungan antara Index dan Weight dilengkapi dengan garis regresi yang menunjukkan tren garis naik ke kanan atas.



Gambar 4.11 Scatter Plot Korelasi Variabel Index dan Weight Ditambah Garis Regresi

Nilai koefisien korelasi Pearson antara Index dan Weight diperoleh sebesar 0,804569, yang mengindikasikan hubungan linear positif yang sangat kuat.

```

[20] # Menghitung matriks korelasi untuk semua kolom numerik
correlation_matrix = df[['Index', 'Weight']].corr(numeric_only=True)

# Menampilkan matriks korelasi
print("Matriks Korelasi:")
print(correlation_matrix)

```

	Index	Weight
Index	1.000000	0.804569
Weight	0.804569	1.000000

Gambar 4.12 Matriks Korelasi Pearson antara Variabel Index dan Weight

4.3 Hasil Data Cleaning dan Encoding

Sebelum tahap pemisahan dataset, variabel kategorikal Gender diubah menjadi bentuk biner numerik menggunakan fungsi `pd.get_dummies()`, yang menghasilkan dua kolom baru yaitu `Gender_Female` dan `Gender_Male`.

```
[21] # Mengubah data bernilai string / object menjadi numerik
df_encoded = pd.get_dummies(
    df,
    columns=['Gender'],
    dtype=int
)

print("Data setelah One-Hot Encoding:")
display(df_encoded.head())
```

--- Data setelah One-Hot Encoding:

	Height	Weight	Index	Gender_Female	Gender_Male
0	174	96	4	0	1
1	189	87	2	0	1
2	185	110	4	1	0
3	195	104	3	1	0
4	149	61	3	0	1

Gambar 4.13 Proses One-Hot Encoding Variabel Kategorikal Gender Menggunakan `pd.get_dummies()`

Selanjutnya, dilakukan pemisahan antara variabel independen/fitur (X) dan variabel dependen/target (y).

```
[22] # Memecah Variabel X & Y
X = df_encoded.drop('Index', axis=1)
y = df_encoded['Index']

print("X:")
display(X.head())

print("y:")
display(y.head())
```

--- X:

	Height	Weight	Gender_Female	Gender_Male
0	174	96	0	1
1	189	87	0	1
2	185	110	1	0
3	195	104	1	0
4	149	61	0	1

y:

	Index
0	4
1	2
2	4
3	3
4	3

dtype: int64

Gambar 4.14 Pemisahan Variabel Independen (X) dan Variabel Dependen (y)

4.4 Hasil Pembagian Dataset

Pembagian dataset diimplementasikan menggunakan fungsi `train_test_split` dari pustaka Scikit-Learn. Skenario pembagian diawali dengan memisahkan 20% data untuk *testing*, dilanjutkan dengan memisahkan 10% dari porsi data *training* untuk *validation*.

```
[23] ✓ Os
from sklearn.model_selection import train_test_split

# Pisahkan data Testing (20%)
X_train_val, X_test, y_train_val, y_test = train_test_split(
    X,
    y,
    test_size=0.20,
    random_state=42
)

# Pisahkan Training dan Validation (Validation = 10% dari data training)
X_train, X_val, y_train, y_val = train_test_split(
    X_train_val,
    y_train_val,
    test_size=0.10,
    random_state=42
)
```

Gambar 4.15 Implementasi Fungsi train_test_split() Menggunakan Scikit-Learn

Dari total 500 record data, diperoleh alokasi akhir sebanyak 360 data *Training*, 40 data *Validation*, dan 100 data *Testing*.

```
[in] ✓ Os
# Output Pemisahan Data
print("Jumlah Data:")
print(f"Training : {len(X_train)} data")
print(f"Validation : {len(X_val)} data")
print(f"Testing : {len(X_test)} data")

print("\n5 Baris Data Training:")
display(X_train.head())

print("\n5 Baris Data Validation:")
display(X_val.head())

print("\n5 Baris Data Testing:")
display(X_test.head())
```

--- Jumlah Data:
 Training : 360 data
 Validation : 40 data
 Testing : 100 data

5 Baris Data Training:

	Height	Weight	Gender_Female	Gender_Male
161	140	52	0	1
367	186	143	1	0
373	163	63	1	0
227	188	123	0	1
404	193	130	0	1

5 Baris Data Validation:

	Height	Weight	Gender_Female	Gender_Male
120	168	87	1	0
122	182	151	0	1
271	152	103	0	1
348	157	60	1	0
272	187	121	1	0

5 Baris Data Testing:

	Height	Weight	Gender_Female	Gender_Male
381	161	103	0	1
73	180	75	0	1
374	174	95	0	1
166	179	103	1	0
104	192	140	1	0

Gambar 4.16 Jumlah Data dan 5 Baris Teratas Hasil Pembagian Training, Validation, dan Testing

BAB V KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan praktikum dan analisis data yang telah dilakukan, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Analisis statistik deskriptif terbukti efektif dalam memberikan pemahaman awal mengenai bentuk distribusi, ukuran pemusatan, serta variabilitas data sebelum memasuki tahap pemodelan.
2. Penggunaan visualisasi data seperti *Boxplot*, *Histogram*, dan *Scatter Plot* mempermudah identifikasi pola hubungan antar-variabel serta pendeteksian *outlier*.
3. Proses *one-hot encoding* berhasil mentransformasi variabel kategorikal menjadi format numerik yang dapat diproses oleh algoritma *machine learning*.
4. Pemisahan dataset menjadi data *training*, *validation*, dan *testing* berhasil dilakukan sesuai proporsi skenario, sehingga ketersediaan *unseen data* untuk evaluasi akhir model tetap terjaga.

5.2 Saran

Adapun saran yang dapat diberikan untuk pengembangan praktikum selanjutnya adalah sebagai berikut:

1. Menerapkan prosedur penanganan *outlier* yang teridentifikasi (seperti *IQR filtering* atau *Winsorization*) agar tidak memengaruhi performa model pada tahap pelatihan.
2. Melakukan proses *feature scaling* (seperti normalisasi Min-Max atau Standardisasi Z-score) pada variabel numerik sebelum dilakukan pelatihan model.
3. Menggunakan teknik *K-Fold Cross Validation* sebagai alternatif evaluasi performa model apabila ukuran dataset yang digunakan relatif terbatas.

DAFTAR PUSTAKA

- [1] Sugiyono, *Metode Penelitian Pendidikan (Pendekatan Kuantitatif, Kualitatif dan R&D)*. Bandung, Indonesia: Alfabeta, 2013.
- [2] W. H. Syaifudin and A. Choiruddin, *Pengantar Teori Probabilitas dan Statistika*. Elmarkazi Publisher, 2021.
- [3] R. E. Walpole, R. H. Myers, S. L. Myers, and K. Ye, *Probability & Statistics for Engineers & Scientists*, 9th ed. Boston, MA, USA: Pearson, 2012.
- [4] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2017.
- [5] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.